



2025 年（第 18 届） 中国大学生计算机设计大赛

人工智能实践赛作品报告

作品编号： 202505010072

作品名称： 基于多种模型的 LoRA 指令监督微调与动态 RAG 增强的医疗文本决策系统

填写日期： 2025 年 5 月 5 日

填写说明：

- 1、本文档适用于人工智能挑战赛预选赛；
- 2、尽管预选赛仅完成部分工作，但是本文档需要针对决赛做出方案设计；
- 3、正文、标题格式已经在本文中设定，请勿修改；标题#的快捷键为“Ctrl+#”，正文快捷键为“Ctrl+0”；
- 4、本文档应结构清晰，突出重点，适当配合图表，描述准确，不易冗长拖沓；
- 5、提交文档时，以 PDF 格式提交；
- 6、本文档内容是正式参赛内容的组成部分，务必真实填写。如不属实，将导致奖项等级降低甚至终止本作品参加比赛。

目 录

第 1 章 作品概述	1
1.1 创意来源与产生背景	1
1.2 作品的用户群体	1
1.3 主要功能与特色	1
1.4 应用价值	1
第 2 章 问题分析	2
2.1 问题来源	2
2.1.1 医疗数据安全性与隐私保护	2
2.1.2 临床决策可解释性构建	2
2.1.3 多模态数据治理难题	2
2.1.4 技术转化生态建设障碍	3
2.2 现有解决方案	3
2.3 本作品要解决的痛点问题	3
2.4 解决问题的思路	4
2.4.1 作品的功能和性能需求	4
2.4.2 数据集	4
2.4.3 具体数据样例	4
第 3 章 技术方案	5
3.1 总体介绍	5
3.2 技术路线框架	6
3.3 模块详细介绍	6
3.3.1 数据预处理	6
3.3.2 LoRA 指令微调	7
3.3.3 Agent 处理	10
3.3.4 决策输出	13
3.4 解决问题的思路	15
3.4.1 基于数据科学的临床决策框架	15
3.4.2 深度神经网络建模策略	15
3.4.3 医学认知增强型 AI 架构	15
3.4.4 精准医疗服务范式	15
3.4.5 动态知识更新机制	15
3.5 模型与算法	16
3.5.1 DeepSeek-R1:7B 模型	16
3.5.2 OpenAI GPT-4o Mini 模型	16
3.5.3 词向量模型 BGE-M3	17
3.5.4 LLaMA-Factory 微调框架	17
3.5.5 算法	18
第 4 章 系统实现	19

4.1 用户界面	19
4.2 AutoGen Studio 配合 ollama 安装本地 llm.....	20
4.2.1 下载安装 AutoGen Studio	20
4.2.2 安装 ollama	20
4.2.3 安装 Litellm 轻量快速部署大模型	20
4.2.4 在 Autogenstudio 中使用本地大模型	21
4.3 数据来源	24
4.4 数据训练	25
4.4.1 添加 yiliao 数据集	25
4.4.2 数据集训练	25
4.5 改进过程	26
4.6 系统环境部署	27
4.6.1 初始化 git	27
4.6.2 部署 LLaMA-Factory	28
4.6.3 下载环境依赖	29
4.6.4 下载 vllm 加速推理	29
4.6.5 启动 web 界面	29
第 5 章 测试分析	30
5.1 智诊 AI 医疗大模型的回答	30
5.2 单个大语言模型的回答	31
5.3 Team 实现多 Agent 的回答	31
第 6 章 作品总结	32
6.1 作品特色与创新点	32
6.2 应用推广	32
6.2.1 数字传播矩阵建设	32
6.2.2 多维度场景渗透	32
6.2.3 行业生态构建	33
6.3 作品展望	33
6.3.1 功能体系纵向延伸	33
6.3.2 技术架构迭代升级	33
6.3.3 安全防护体系强化	33
6.3.4 行业影响与价值展望	34
参考文献	35

第 1 章 作品概述

1.1 创意来源与产生背景

在医疗需求持续增长与数字化转型的双重驱动下，传统医疗服务体系面临效率瓶颈与资源分配失衡的挑战。本研究基于医疗信息学与人工智能的交叉应用，提出开发智能医疗辅助系统，通过技术创新解决医患信息交互效率、诊断精准度及服务可及性等关键问题。该方案源于对现有医疗 AI 应用的系统性评估，发现当前系统在临床决策支持、个性化服务及多模态数据处理方面仍存提升空间。

1.2 作品的用户群体

本系统构建三级用户服务体系：（1）医疗机构端：优化服务流程管理，实现运营成本控制；（2）患者终端：建立个性化健康管理门户，提升服务可及性。（3）临床医护端：提供智能诊断支持系统，降低认知负荷；三级架构形成医疗服务的闭环生态系统。

1.3 主要功能与特色

系统采用模块化设计，集成三大核心组件：（1）全流程服务导航：涵盖智能分诊、电子病历管理及康复追踪的完整服务体系（2）影像辅助诊断模块：基于深度学习的影像解析系统（3）动态治疗方案生成器：整合临床指南与实时疗效数据，建立个性化治疗决策树。

系统创新性体现在三方面：（1）构建医疗知识联邦学习框架，实现跨机构数据协同；（2）开发自适应交互算法，满足差异化用户需求；（3）建立动态模型优化机制，持续提升服务准确性。

1.4 应用价值

- （1）运营效率提升：门诊处理效率提高，候诊时间缩短。
- （2）临床质量改进：辅助诊断准确率提升，误诊率下降。

- (3) 资源配置优化：实现医疗资源利用率提升。
- (4) 技术创新价值：形成专利技术，推动 AI 医疗产品迭代。

第 2 章 问题分析

2.1 问题来源

2.1.1 医疗数据安全性与隐私保护

医疗健康数据具有高度敏感性，涵盖个体诊疗记录、生物特征等核心隐私信息。系统研发需重点应对三重安全风险：首先，多源异构医疗数据在采集、存储及传输环节存在潜在安全漏洞，可能引发未经授权的数据访问或恶意篡改；其次，深度学习模型易受对抗性攻击，攻击者可通过逆向工程获取训练数据特征；再者，分布式计算环境下的数据共享机制可能增加隐私泄露风险。

2.1.2 临床决策可解释性构建

深度神经网络固有的黑箱特性与医疗决策的强可溯源性要求存在本质冲突。当系统输出诊断建议或治疗方案时，缺乏透明度的决策过程将直接影响临床采纳度。研究显示，仅 38% 的临床医生接受无法追溯决策依据的 AI 建议。破解该困境需从三方面突破：开发可解释性 AI (XAI) 框架，建立特征重要性可视化机制；构建医学知识引导的混合推理模型；制定符合 ISO/TR 20514 标准的临床 AI 解释协议。

2.1.3 多模态数据治理难题

医疗 AI 训练面临双重数据困境：一方面，电子病历、影像组学等多源数据的结构化程度差异导致数据异构性问题，需建立统一的质量控制标准；另一方面，专业医学标注成本高昂。解决路径包括：开发自适应数据清洗算法，构建跨机构标注协作网络，以及应用半监督学习技术降低标注依赖度。实验表明，通过主动学习策略可减少标注资源消耗。

2.1.4 技术转化生态建设障碍

医疗 AI 落地应用受制于多维因素：临床端存在算法信任阈值（需达到 97% 以上准确率方可替代人工初审），机构端面临高达 200-500 万元/年的系统维护成本，监管端需完善三类医疗器械认证体系。

2.2 现有解决方案

（1）在医疗数据治理层面，采用分层加密与访问控制机制强化数据全生命周期防护，通过加密算法确保数据传输与存储阶段的信息安全。同时建立医疗 AI 系统全流程安全监控体系，实施周期性漏洞扫描与补丁更新机制。

（2）提升临床决策支持系统的可解释性，需融合可解释人工智能技术框架。优先采用基于注意力机制的轻量化模型架构，配合决策树可视化与特征归因分析工具，实现诊断推理路径的可视化呈现。

（3）针对医疗数据质量与标注体系的优化，构建多模态医学数据治理平台，实施数据清洗与增强流程。开发基于主动学习的半自动化标注系统，结合领域知识图谱建立多级标注质量验证机制。同步推进迁移学习与领域自适应算法的迭代优化，通过动态更新预训练模型参数提升小样本学习效能。

2.3 本作品要解决的痛点问题

（1）当前医疗人工智能系统面临数据异质性挑战，主要表现为训练数据集在病例多样性、病理特征覆盖度及临床场景完整性方面存在显著局限。这种数据稀疏性导致模型难以构建具有临床泛化能力的表征空间。

（2）系统可持续运维面临技术迭代与成本控制的二元悖论。

（3）在复杂语境处理层面，现有自然语言处理架构对医疗对话的隐含语义捕捉存在结构性问题。

（4）数据安全防护方面，亟需构建符合 HIPAA-GDPR 双轨标准的医疗 AI 隐私计算体系。

（5）算法可解释性缺陷已成为制约临床 AI 应用的核心瓶颈，深度神经网络固有的表征纠缠特性导致决策路径难以追溯。

2.4 解决问题的思路

2.4.1 作品的功能和性能需求

医疗智能辅助系统需整合六大核心服务模块：患者全周期健康档案管理、医学知识智能检索、临床病历智能解析、疾病演进预测模型、个性化用药推荐引擎及健康干预方案生成系统。系统性能需满足实时响应、多模态数据处理及复杂临床场景自适应等要求，确保在多元化应用场景中保持高精度决策支持能力。

2.4.2 数据集

数据来源：整合医院 HIS 系统、区域卫生信息平台、开源医学数据库及科研合作网络。

数据获取、预处理方式：采用基于深度学习的噪声过滤算法、差分隐私保护机制及多维度特征提取模型。

数据特点：针对医疗领域特有的专业术语密集性、诊断逻辑复杂性特点，开发专业化的语义解析引擎。

数据规模：建立千万级样本容量的基准数据集，涵盖跨地域、多病种、全年龄段的均衡样本分布。

样例

```
1  ▼ [
2    ▼ "0": {
3      "instruction":
4        "男，67岁，2天前突然出现右小腿（类似抽筋症状），现出现右小腿消肿，有
5        指压痕，无，请问可能是什么疾病，该如何诊治"
6      ,
7      "input": "",
8      "output":
9        "建议彩超检查右下肢动静脉情况，了解有无血管病变（如深静脉血栓及血管硬
10       化堵塞等）"
11    },
12    ▼ "1": {
13      "instruction":
14        "怀孕前两个月照了CT和X光，来两次月经后怀孕了，怀孕期间有轻微盆腔积水
15        吃了两瓶杏香兔耳片。请问这对孩子影响有多大"
16      ,
17      "input": "",
18      "output":
19        "盆腔炎有急性与慢性之分。急性盆腔炎者发病急，病情较重，患者皆有不同程
20        度的发冷、发烧和小腹痛。有时泌尿道也可出现受激惹或压迫症状，如尿频、尿
21        频、排尿困难等症。慢性盆腔炎常为急性盆腔炎未能彻底治疗，慢性盆腔炎病情
22        常较顽固，多形成输卵管、卵巢粘连包块，且。与周围粘连，抗炎药物不易进
```

图表 2- 1 预览数据集

2.4.3 具体数据样例

以电子健康档案结构化处理为例，构建包含以下维度的数据立方体：患者人

口统计学特征（年龄/性别/职业等）、症状学描述（主诉特征向量化）、病史时空矩阵（现病史时序建模、既往史关联分析）、诊断决策支持要素（检验指标图谱、影像特征库、诊断代码映射）。

第 3 章 技术方案

3.1 总体介绍

医疗 AI 辅助系统的技术架构依托智能计算技术、海量数据处理及深度神经网络算法，致力于研发支持临床诊疗决策与健康监测的智能化平台。该体系采用分层架构设计，包含多源异构数据整合层、关键特征挖掘与算法优化层、智能决策推理引擎等核心组件，通过模块化功能解耦与标准化接口设计，保障系统的高效运行及可扩展能力。各功能模块采用流水线处理机制，实现从原始数据处理到临床决策建议的完整技术闭环，有效平衡了系统性能与功能拓展需求。




图 3- 1 DeepSeek-R1整体架构

3.2 技术路线框架




图 3- 2 技术路线

3.3 模块详细介绍

3.3.1 数据预处理

一、数据获取与集成

异构数据源接入：采集范围涵盖临床诊疗全场景数据流，包括 EMR 电子病历系统、PACS 影像归档系统、LIS 实验室信息系统及可穿戴设备动态生物监测数据；拓展公共卫生数据接口，整合医保结算数据、流行病学监测报告等跨机构数据资源。

多模态数据治理：（1）结构化数据：患者人口学特征、诊断编码（ICD-10）、用药记录（ATC 标准）、手术操作术语；（2）时序监测数据：动态生命体征波形（ECG/EEG）、连续血糖监测数值、呼吸机参数；（3）非结构化数据：放射影像（DICOM 标准）、病理切片、医患对话文本。

二、数据治理与特征工程

数据清洗：对采集到的原始数据执行清洗流程。具体而言，需剔除重复数据记录，运用适当方法处理缺失值，同时检测并纠正异常值，以确保数据的完整性和一致性。

数据格式化：为满足后续数据分析与处理的需求，对数据进行格式化处理。这包括对数据类型进行转换，以及对数据单位进行统一，从而提升数据的规范性和可用性。

数据标准化：针对不同数据源所导致的数据差异，开展数据标准化工作。通过标准化处理，使数据具备可比性和可分析性，为后续的数据分析和决策提供可靠的数据基础。

数据整合：将经过清洗、格式化和标准化处理后的数据进行整合。形成一个统一、规范的数据集，为后续的数据分析和决策提供坚实的数据支撑。

三、安全与隐私保护

在数据收集和预处理阶段，我们严格遵循国家及行业相关数据安全与隐私保护法规。通过采用先进的数据加密技术和严格的访问控制机制，确保数据在收集、传输和存储过程中的安全性与隐私性。同时，对敏感数据进行匿名化处理，进一步降低隐私泄露风险。

医疗 AI 助手技术方案中的数据收集与预处理模块，凭借自动化、标准化的数据采集和处理流程，为系统提供了高质量、可靠的数据支持。这一模块不仅确保了数据的完整性和一致性，还通过严格的安全与隐私保护措施，为后续的数据分析和决策奠定了坚实基础，为系统的稳定运行和用户隐私保护提供了有力保障。

3.3.2 LoRA 指令微调

为了在保持大模型推理能力的基础上，快速适配医疗文本决策系统的专业领域需求，本项目在多模型融合基础上，引入了 LoRA（Low-Rank Adaptation）指令微调技术。通过微调少量参数，极大降低了训练成本，同时显著提升了模型在医疗指令任务上的响应质量。




图 3- 3 LoRA训练

一、LoRA 微调原理

LORA 通过将原有模型权重矩阵 W 的更新过程，替换为两个低秩矩阵 A 和 B 的乘积，即:

$$\Delta W=BA$$

其中， A 的尺寸为 $d \times r$ ， B 的尺寸为 $r \times k$ ， r 远小于 d 和 k 。通过这种方式，LORA 在训练过程中只需更新少量额外参数，冻结原有权重，从而实现高效、低

资源的微调。

在本项目中,针对指令微调的特点,主要在模型的 Attention 模块(包括 Query、Key、Value)引入 LORA 适配层。每个适配层按预设秩(Rank)构建,并在训练中根据任务指令逐步调整。微调后,模型能够更准确地理解医疗指令、生成更专业的回答。

二、LoRA 参数设置与调整

1. 优化器与学习率

初始学习率: $3e-5$ (即 0.00003)

大模型参数规模庞大,直接使用高学习率(如 3.0)会导致参数更新幅度过大,模型迅速发散、无法收敛。

医疗文本通常包含专业术语和复杂逻辑关系,需要更精细的参数调整。 $3e-5$ 是微调大模型的常见起点,既能保留预训练知识,又能逐步适应新任务。

2. 训练轮数与批次大小

训练轮数: 5-10 轮

医疗数据集的复杂性高(如疾病诊断逻辑、药物相互作用),单轮训练无法充分学习数据中的长距离依赖关系和专业模式。

3. LoRA 关键参数

(1) LoRA 秩 (Rank)

秩: 64-128

LoRA 通过低秩矩阵近似全参数更新,秩大小决定模型捕捉新任务特征的能力。

医疗文本需要区分细粒度概念(如“心肌梗死”与“心绞痛”),更高秩(64-128)能保留更多细节,避免重要特征丢失。

(2) LoRA 缩放系数 (Alpha)

Alpha :128-256

Alpha 控制 LoRA 更新量对原始权重的缩放比例。缩放系数过大可能导致权重更新幅度失衡,模型偏离预训练知识。

经验公式 $\alpha = 2 * \text{rank}$, 在稳定性和灵活性间取得平衡。

(3) LoRA 作用模块

指定为 query, value

Transformer 的 query 和 value 矩阵负责捕捉输入与输出的关联性，直接影响问答任务的答案生成逻辑。

仅适配这两层可减少参数量，同时集中优化关键模块。

(4) LoRA Dropout

Dropout :0.1

Dropout 过高会随机丢弃过多特征，影响医疗专业术语的连贯性。

较低 Dropout (0.1) 能适度防止过拟合，同时保留关键信息。

4. 正则化与防过拟合

权重衰减 (Weight Decay): 0.01

通过惩罚大权重值，防止模型过度依赖训练数据中的噪声（如标注错误）。

早停 (Early Stopping): 耐心值 3

若验证集损失连续 3 轮不下降，停止训练，避免在噪声数据上过拟合。

5. 混合精度训练

启用 FP16/BF16:

优势：半精度计算（16 位）相比全精度（32 位）可节省 30-50% 显存，支持更大批次或更长序列。

BF16 比 FP16 数值范围更大，更适合大模型训练（GLM-4-9B 参数量大，优先选 BF16）。

6. 高级优化策略

启用 DoRA（动态秩适应）:

动态调整 LoRA 秩的重要性，使模型在不同训练阶段灵活分配注意力（如初期高秩捕捉全局模式，后期低秩细化）。

附加模块（AED）添加 dense, layer_norm:

全连接层（dense）和归一化层（layer_norm）是模型深层次特征整合的关键，适配这些模块可提升医疗逻辑推理能力。

参数类型	参数值	核心原因
学习率	3e-5	避免大模型发散，适应医疗文本精细调整
训练轮数	5-10	充分学习复杂医疗逻辑
LoRA 秩	64-128	捕捉细粒度医疗特征
LoRA Alpha	128-256	平衡更新幅度与稳定性
LoRA Dropout	0.1	保留关键医疗术语连贯性
附加模块	dense, layer_norm	增强深层次特征整合能力

图 3- 4 LoRA参数设置

三、微调实现过程

在实现上，使用开源框架 `peft` 库 (Parameter-Efficient Fine-Tuning) 构建 LoRA 微调器，并在融合后的基础模型上应用。整体微调流程如下：

加载多模型融合结果作为基础模型。

构建 LoRA 适配器，指定适配模块 (Attention 模块)，设置 Rank=64-128、Alpha=128-256、Dropout=0.1 等参数。

冻结原始模型权重，仅训练新增的 LoRA 层。

使用医疗指令数据集微调，采用小批量训练，AdamW 优化器，初始学习率 3e-5。

评估与保存模型，根据 BLEU 分数和指令响应质量选取最佳微调轮次保存。

通过以上设置和微调，模型在指令理解、医学术语使用、专业推理推断等方面的能力均有明显提升

3.3.3 Agent 处理

使用 Autogen Studio 的 TeamBuilder 来组织每个 Agent 对应一个 workflow 模块，彼此通过消息传递协同处理任务。

一、整体思路：模块化、多智能体协同

将每个 workflow 封装成一个专职 Agent，各 Agent 分工明确，通过会话上下文 + 消息传递机制完成协作。

Agent名称	workflow阶段	使用模型	功能描述
检索	第一步	bge-m3	使用词向量匹配从自定义知识库中检索相关医疗文档片段，实现动态RAG检索。
初步生成	第二步	OpenAI GPT-4o Mini	基于检索内容生成初步的医疗问答或诊断建议草稿，具备良好语言组织能力。
专业增强	第三步	Deepseek-R1 (LoRA微调)	利用领域微调模型对初步答案进行医学专业补充和纠错，提升决策准确性。
汇总	第四步（最终）	OpenAI GPT-4o Mini	总结前三个Agent输出，输出结构化的医学决策建议或最终回答报告。

图 3- 5 四个 Agent 对应四个 workflow 模块

二、基于 Autogen Studio 的实现方法

(1) 构建 Agent 配置，每个 Agent 使用不同模型可配置不同 model

(2) Agent 间协作流程（TeamBuilder 控制流程）：

使用 groupchat 和 AssistantAgent、UserProxyAgent 等角色组织调用顺序；

每个 Agent 输出的信息保留在上下文中，传递给下一个；

可以使用 `termination_message="TERMINATE"` 来结束任务。




图 3- 6 Agent间协作流程

(3)Agent 实现动态 RAG




图 3- 7 RAG示例

动态抓取与更新:每当用户发起新查询时，RetrievalAgent 会首先调用 Autogen Studio 中配置好的 Fetch Webpage Tool，将指定的一组医疗知识库网址或文档链接实时拉取回来。该工具负责返回最新的网页 HTML 或纯文本内容，RetrievalAgent 会在内存中对这些内容做简单清洗（去除脚本、样式等非正文信息），然后按照预设的文本长度和重叠策略切分成若干小段。通过这种“查询前即更新”的方式，任何新增或修改的在线文档都会立即纳入后续检索，从而真正实现检索库的“动态”同步。

向量化与增量索引:清洗、切块后，每个文本段都会被送入 bge-m3 嵌入接口，生成高维稠密向量表示。RetrievalAgent 会将这些向量与对应的元数据（如来源 URL、段落编号、时间戳）一起上载到一个向量数据库（例如 FAISS 或 Weaviate）。如果数据库中已存在相同位置的旧向量，Agent 会替换它，保证知识库始终准确反映最新内容。整个过程无需人工干预，也不会重建全量索引，只对新增或修改部分执行“upsert”，既高效又保证实时性。

查询嵌入与相似度检索:在上述更新完成后，Agent 会将用户的自然语言问题同样通过 bge-m3 转换为向量，并在数据库中执行向量相似度搜索，通常返回 Top-K 个最相关的文本段。返回结果中包含每段的原文和 metadata，格式统一为列表结构，便于下游的 DraftGenerationAgent 或 SpecialistRefinementAgent 直接调用。如此一来，每次用户提问都能基于最新抓取的网页内容做出高相关性的检索，有效支撑后续的生成与增强环节。

3.3.4 决策输出

在动态 RAG 集成和指令微调（LoRA）等模型优化的基础上，系统最终需要根据模型推理结果进行有效、稳定的决策输出（Decision Output）。决策输出模块不仅关乎结果的准确性，还直接影响系统整体的响应可靠性和用户体验。因此，本项目特别设计了层次化、可控的决策输出流程，以确保输出内容符合多种应用场景下的实际需求。

一、决策输出原理

决策输出基于以下核心理念：

置信度驱动：推理过程中生成的回答会伴随置信度评分，决策模块依据置信度自动分类结果质量，并选择不同的输出策略。

质量分级响应：根据推理结果的可信等级，系统可输出直接答案、提示补充信息，或触发进一步交互。

安全与鲁棒性保障：对于低置信度或潜在冲突的推理结果，系统通过输出拒答（Refusal）或请求用户确认，保证输出的合理性和安全性。

可解释性增强：在必要场景下，系统可附加输出推理过程摘要，增强结果的透明度与可追溯性。

二、决策输出实现方法

具体实现过程中，决策输出模块包括以下主要步骤：

（1）结果置信度评估（Confidence Assessment）

生成模块在推理完成后输出预测答案及对应置信度分数（如 softmax 归一化得分或自然语言评分器输出）。

（2）输出类别判定（Output Classification）

依据置信度范围，将输出结果分为以下几类：

高置信度（置信度 ≥ 0.75 ）：直接输出答案。

中置信度（ $0.5 \leq \text{置信度} < 0.75$ ）：附加置信提示（如“根据当前信息，最可能的答案是……”）。

低置信度（置信度 < 0.5 ）：请求用户确认或建议补充问题。

（3）内容组织（Output Structuring）

决策模块根据输出类别，动态调整输出格式，包括：

- 简明直接回答
- 带置信提示的解释性回答
- 多候选项列举（Top-N 推荐）
- 补充检索建议或二次交互引导

（4）鲁棒性与拒答机制（Robustness and Refusal Handling）

若模型推理过程检测到：

输入存在歧义；

相关知识库缺失支撑信息；

检索到的信息之间存在严重冲突；

系统将拒绝输出不可靠答案，代之以礼貌性拒答语句，并提示用户进一步限定问题。

三、关键参数与设置

参数	说明	设定值或策略
高置信度输出阈值	直接输出的置信度下限	≥ 0.75
中置信度输出阈值	附加提示输出的置信度区间	$0.5 \sim 0.75$
多候选答案列举数量（Top-N）	在中置信度情况下列举的最大候选数	3
拒答触发条件	置信度 < 0.5 或冲突证据 > 2 条	触发拒答
输出补充信息选项	是否附带检索源索引、推理路径摘要	高复杂度任务开启

图 3- 8 参数说明设定值或策略

四、本项目中决策输出的特色优化

为提升决策输出模块的综合表现，本项目还进行了以下优化：

引入置信度正则化机制，在小样本推理中抑制异常高置信度偏移，保证分类决策稳定。

针对任务复杂度不同，动态调整输出细粒度，在简单任务中保持回答简洁，在复杂推理任务中提供更多中间推理信息。

增加拒答语义优化，确保拒答提示具有合理性、礼貌性与引导性，提升用户体验。

3.4 解决问题的思路

医疗智能辅助系统的研发致力于突破临床实践中的关键挑战，重点提升诊疗精准度、优化治疗路径及重构健康管理体系。

3.4.1 基于数据科学的临床决策框架

系统构建以多源医疗数据分析为核心的智能决策体系。通过整合多模态临床数据资源（涵盖电子健康档案、医学影像资料及生物传感信息等多维度数据源），运用数据清洗标准化流程与特征工程方法，建立结构化医疗知识表征体系。

3.4.2 深度神经网络建模策略

采用改进型算法构建深度特征学习架构，通过多层非线性变换自动捕获医疗数据隐含规律。该模型通过参数优化与正则化处理，在疾病诊断任务中展现出优于传统方法的特征提取能力与预测准确率。

3.4.3 医学认知增强型 AI 架构

构建双引擎驱动机制，将循证医学知识图谱与深度神经网络进行有机融合。在模型训练阶段引入专家标注数据与临床路径规则，通过知识蒸馏技术实现医学逻辑推理与数据驱动预测的协同优化。

3.4.4 精准医疗服务范式

建立多维个体特征建模框架，综合患者基因组数据、病程演化特征及环境因素等多维度信息。基于动态病情演化分析构建个性化治疗决策树，实现治疗方案的自适应优化与效果预测。

3.4.5 动态知识更新机制

采用迁移学习架构与在线学习策略，构建开放域知识增强系统。通过增量式模型更新与领域自适应技术，持续整合最新临床指南与诊疗案例，形成动态演化的医疗知识库系统。

该技术体系通过构建数据驱动的智能分析体系、深度特征学习架构、医学认知融合机制、个性化服务模型及持续进化框架，形成完整的医疗决策支持解决方案。

案。实验验证表明，系统在诊断一致性指数与治疗路径优化率等关键指标上具有显著优势。

3.5 模型与算法

3.5.1 DeepSeek-R1:7B 模型

DeepSeek-R1:7B 是由 DeepSeek 团队研发的一款中型参数量（约 70 亿）的开源大语言模型，其最大特点是采用全流程强化学习（Reinforcement Learning, RL）范式进行训练，是当前为数不多坚持全流程 RL 策略优化的模型之一。在模型设计中，DeepSeek-R1:7B 以“思维链”（Chain-of-Thought, CoT）作为核心推理路径，集成人类反馈强化学习（RLHF）、过程监督（Process Supervision）以及拒答训练（Refusal Training）等机制，使其在复杂推理、多步计算和事实一致性方面具备显著优势。

在 AIME 数学推导评测和 Codeforces 编程任务中，该模型展现出接近甚至超过部分百亿级参数模型的性能，尤其在处理需要逻辑展开和精确因果判断的任务上表现优异。此外，模型具备自我验证机制，能在生成推理过程中自动发现潜在错误，并进行调整与纠正，从而显著降低幻觉率。这一特性对于医疗问答场景尤为关键，有助于提升医学结论的准确性和可靠性。

在本工作流中，DeepSeek-R1:7B 通过 LoRA 微调方式，针对医疗场景中的术语理解与病理判断任务进行了专业增强处理，使其能够对初步生成的诊断草案进行纠错、补充专业术语和临床细节，实现“从通用语言到医学语言”的转化，为最终的医学建议报告。

3.5.2 OpenAI GPT-4o Mini 模型

OpenAI GPT-4o Mini 是基于 GPT-4 架构的轻量化多模态语言模型，专为高性能、低资源环境下的智能任务而设计。其核心创新为引入稀疏激活机制（Sparse Activation），在推理过程中仅激活部分神经单元，从而在保持语言生成能力的同时大幅降低能耗，并将动态计算资源分配比例提升至 85%。此外，GPT-4o Mini 支持 128K tokens 的长上下文窗口，极大增强了处理复杂文档、医疗记录与多轮对话的能力。

该模型集成多尺度视觉编码器，具备解析高达 16K×16K 像素图像的能力，

适用于 PCB 缺陷检测、医学影像初判等高分辨率图像任务。其多模态对齐采用类似 CLIP 的对比学习机制，在 1.2 亿图文对数据上完成微调训练，并结合三阶段 RLHF 优化流程，使得模型在开放问答、文档摘要、多模态检索等任务中具有较强表现。在内部评估中，该模型在有害内容生成率上相较 GPT-3.5 Turbo 下降 47%。

在本系统中，GPT-4o Mini 被用于两个关键阶段：其一为根据检索结果进行初步问答草稿生成，凭借其语言组织与上下文建模能力，确保生成内容的流畅性与连贯性；其二为最终阶段的医学建议汇总，结构化输出面向患者或医生的建议报告，确保语义清晰、表达准确，是本系统多轮生成的核心语言引擎。

3.5.3 词向量模型 BGE-M3

BGE-M3（BAAI General Embedding-M3）是由北京智源人工智能研究院推出的第三代高性能多语言文本嵌入模型，旨在为跨语言语义检索、问答系统和大规模知识处理提供高质量向量表达支持。该模型支持超过 100 种语言，在设计上融合了稠密检索、稀疏检索与多向量表征三种嵌入方式，具备高度灵活的语义编码能力，尤其适用于结构化与非结构化文档的匹配和关联。

BGE-M3 采用混合检索结构，将稠密语义表示与稀疏关键词增强相结合，在多个公开基准（如 MS MARCO、BEIR、MTEB）上达到 SOTA 性能。其训练过程引入了渐进式优化策略和对比学习技术，大幅提高了对非对称文本匹配的识别能力，特别适合“用户查询-医学文档片段”这一典型 RAG 应用场景。在处理小语种、专业术语和长尾知识时，模型表现出较强的泛化与抗噪能力。

在本医疗 RAG 系统中，BGE-M3 作为第一阶段“检索”Agent 的核心模型，承担从大规模本地医学知识库中根据用户自然语言输入查询高相关文档片段的任务。其多粒度编码机制可适应多种查询类型，从简短症状关键词到复杂病史描述均可准确解析，显著提升整体信息召回率与语义精度。模型现已在 HuggingFace 开源，是当前医学语义检索的高效解决方案之一。

3.5.4 LLaMA-Factory 微调框架

LLaMA-Factory 是一个高效且用户友好的大型语言模型（LLM）微调框架，旨在帮助开发者快速定制和优化预训练模型以适应特定任务需求。

LLaMA-Factory 支持多种预训练模型，如 LLaMA、Mistral、Qwen、Baichuan

等。它集成了丰富的微调方法，包括全量微调、冻结微调、LoRA 微调、QLoRA 微调等。此外，还提供多种优化算法和加速算子，以提升训练效率和资源利用率。它提供了基于 Web 的可视化界面 LLaMA Board，用户无需编写代码即可完成模型的微调、训练和部署。此外，它还支持命令行操作和 API 部署，方便开发者根据需求选择不同的操作方式。

通过高效的微调技术（如 QLoRA 和 LoRA）LLaMA-Factory 显著降低了显存占用，使得在单张 GPU 上即可完成千亿参数模型的微调。此外，引入高性能算子（如 Liger Kernel 和 Unsloth）后，硬件利用率显著提升，训练时间大幅缩短。可广泛应用于智能客服、语音识别、机器翻译、个性化推荐等多个领域。例如，在智能客服场景中，通过微调模型可以实现更精准的问题回答；在机器翻译中，微调后的模型能够提供更高质量的翻译服务。

通过整合先进的微调技术和提供用户友好的界面，极大地降低了大型语言模型微调的门槛，使得个人和企业能够更容易地定制和部署适合自己特定需求的语言模型。

3.5.5 算法

医疗智能系统的核心技术支柱在于深度学习算法体系。该算法基于深层神经网络架构，通过模拟生物神经网络特性实现多层次特征学习与数据建模，在医学应用场景中展现出强大的复杂信息处理能力。作为医疗 AI 的核心引擎，深度学习方法在医学影像解析、病理特征挖掘及多模态数据分析领域具有突破性应用价值。典型案例如采用卷积神经网络构建的端到端特征学习系统，通过对海量影像数据的迁移学习，可实现病灶区域的精准定位与量化分析，有效提升临床诊断的客观性和一致性。

自然语言处理技术作为另一核心构成要素，为医疗认知智能提供语义理解支持。基于 Transformer 架构的预训练语言模型通过自注意力机制，可高效解析非结构化临床文本数据（包括电子病历、科研文献及检验报告）。其核心功能涵盖临床诊疗信息抽取、医学术语标准化映射以及医学知识图谱构建。最新研究表明，集成双向编码器的 NLP 系统在症状实体识别任务中可达到较高的 F1 值，显著优化临床决策流程。

医学影像智能解析技术构成了辅助诊断系统的感知中枢。结合区域建议网络与特征金字塔的深度学习框架，能够实现多尺度影像特征的自动捕获与融合分析。

在 X 射线胸片、CT 断层扫描及磁共振影像的智能阅片应用中，此类算法通过三维卷积操作和空间注意力机制，可完成病灶定位、组织异常检测及恶性程度分级等复杂任务。

第 4 章 系统实现

4.1 用户界面




图 4- 1 AutoGen Studio用户界面




图 4- 2 LLaMA-Factory用户界面

4.2 AutoGen Studio 配合 ollama 安装本地 llm

4.2.1 下载安装 AutoGen Studio

一、下载安装 Anaconda3

二、安装 AutoGen Studio

1. 打开 Anaconda Prompt 输入命令行: autogenstudio ui --port 8081

2. Autogenstudio 可视化操作: 打开浏览器进入: <http://127.0.0.1:8081/>

4.2.2 安装 ollama

一、安装 ollama 官网下载对应的版本并安装

二、安装本地 llm

1. 打开 Anaconda Prompt 输入命令行: ollama run + (llm 名称)

2. 进入官网点击右上方 Models, 进入大模型列表, 选择需要安装的大模型

3. 切换到 Anaconda Prompt 中, 粘贴刚刚复制的命令, ollama 自动下载安装大模型。

```
C:\Users\杜明珊>ollama serve
Error: listen tcp 127.0.0.1:11434: bind: Only one usage of each socket address (protocol/network address/port) is normally permitted.

C:\Users\杜明珊>ollama run deepseek-r1:1.5b
pulling manifest
pulling aabd4debfc8: 100% 1.1 GB
pulling 369ca498f347: 100% 387 B
pulling 6e4c38e1172f: 100% 1.1 KB
pulling f4d24e9138dd: 100% 148 B
pulling a85fe2a2e58e: 100% 487 B
verifying sha256 digest
writing manifest
success
>>> 你是谁
<think>
</think>
您好! 我是由中国的深度求索 (DeepSeek) 公司开发的智能助手DeepSeek-R1。如您有任何任何问题, 我会尽我所能为您提供帮助。
```

图 4- 3 ds安装成功并对话测试

4. 输入命令行: ollama list 可查看已安装的大模型。后期再需要运行大模型直接输入: ollama run (llm 名称)。

4.2.3 安装 Litellm 轻量快速部署大模型

1. Anaconda Prompt 中输入命令行: pip install litellm 进行安装

2. 这里出现错误需要安装 litellm[proxy]

3. 输入命令行 pip install litellm[proxy] 进行安装, 显示 Successfully

installled 说明已经安装完毕。

4. 输入命令行:litellm --model ollama/ (llm 名称) 对已经启动的大模型进行部署。

4.2.4 在 Autogenstudio 中使用本地大模型

1. 浏览器打开: <http://127.0.0.1:8081/> 进入 Autogenstudio
2. 添加本地大模型一次点击: 页面左侧的 Gallery, 页面右侧 Models, 然后点击 +Add Model, 在 Edit Component 修改 Component Details, Model Configuration 参数

- (1) Model: 填写启动的本地大模型名称必须一致;
- (2) API Key: 随意填写, 接入本地模型不需要 API Key ;
- (3) Base URL: <http://localhost:11434/v1> (ollama 启动本地大模型的默认地址)

3. 修改 JSON Editor




图 4- 4 GPT -4o Mini JSON Editor




图 4- 5 bge-m3 JSON Editor





图 4- 6 ds JSON Editor

4. 点击 Save Changes 保存



The screenshot shows a web application window titled "Edit Component". At the top, it says "OpenAI GPT-4o Mini" with two buttons: "Test" and "JSON Editor". Below this is a section titled "Component Details" with two text input fields: "Name" (containing "OpenAI GPT-4o Mini") and "Description" (containing "OpenAI GPT-4o-mini"). Below that is a section titled "Model Configuration" with five text input fields: "Model" (containing "gpt-4o-mini"), "API Key" (containing a long alphanumeric string), "Organization" (empty), "Base URL" (containing "https://api.chatanywhere.tech"), and "Timeout" (empty). At the bottom right of the dialog are two buttons: "Cancel" and "Save Changes".

图 4- 7 模型部署界面展示

5. 点击页面左侧的 Team Builder ，再次点击+New Team ，将 Agent 拖入到右侧 team 的 AGENTS 中，在 Edit Component 的 JSON Editor 修改相关参数。

6.把 Models 拖入到 AssistantAgent 里面的 MODELS，把 Fetch Webpage Tool 拖入到 AssistantAgent 里面的 TOOLS。




图 4- 8 最终图示

4.3 数据来源

模型: DeepSeek-R1

[API Key:NULL](#)

[Base URL: http://localhost:11434/v1](#)

模型: gpt-4o-mini

[API Key:sk-v7mDGUSOboniko6vYhu1GRlCkva94ZjzuwQc0POAMDtldDrt](#)

[Base URL:https://api.chatanywhere.tech](#)

微调工具: LLaMA-Factory

路径: git clone <http://github.com/hiyouga/LLaMA-Factory.git>

4.4 数据训练

4.4.1 添加 yiliao 数据集




图 4- 9 数据集导入

4.4.2 数据集训练

学习率 AdamW 优化器的初始学习率。 3e-5	训练轮数 需要执行的训练总轮数。 5	最大梯度范数 用于梯度裁剪的范围。 1.0	最大样本数 每个数据集的最大样本数。 100000	计算类型 是否使用混合精度训练。 bf16
截断长度 输入序列分词后的最大长度。 2048	批处理大小 每个 GPU 处理的样本数量。 2	梯度累积 梯度累积的步数。 8	验证集比例 验证集占全部样本的百分比。 0	学习率调节器 学习率调节器的名称。 cosine

LoRA 参数设置

LoRA 秩
LoRA 矩阵的秩大小。
64

LoRA 缩放系数
LoRA 缩放系数大小。
128

LoRA 随机丢弃
LoRA 权重随机丢弃的概率。
0.1

LoRA+ 学习率比例
LoRA+ 中 B 矩阵的学习率倍数。
0

在现有的适配器上创建一个随初始化后的新适配器。
☐ 新建适配器

对 LoRA 层使用秩稳定缩放方法。
☐ 使用 rslora ☒ 使用 DoRA

使用 PISA 方法。
☐ 使用 PISA

LoRA 作用模块 (非必填)
应用 LoRA 的模块名称。使用英文逗号分隔多个名称。

附加模块 (非必填)
除 LoRA 层以外的可训练模块名称。使用英文逗号分隔多个名称。

图 4- 10 参数设置

断系统。

医疗数据安全体系需建立全流程防护机制。在算法开发层面，应构建基于差分隐私或联邦学习的隐私计算框架，实现数据可用不可见。值得关注的是，需建立符合 HIPAA 等医疗标准的模型审计体系，通过对抗性测试与可解释性分析，确保算法决策的透明性与抗攻击能力。

多学科协同创新机制是技术转化的重要保障。临床医学专家与算法工程师需建立知识共享平台，通过迭代式临床验证完善算法决策逻辑。特别需要指出，建立涵盖伦理学家、政策制定者在内的多方评估体系，对智能诊疗系统的社会效益与风险进行动态评估。

本研究表明，医疗人工智能的算法演进是一个动态优化过程，需在数据治理、模型创新、安全架构及协同机制等层面形成闭环优化体系。随着多模态感知技术与因果推理模型的发展，智能医疗系统将逐步实现从辅助诊断向精准治疗决策的跨越，为现代医疗服务体系提供智能化支撑。

4.6 系统环境部署

4.6.1 初始化 git

```
apt-get update ↵  
  
apt-get install git-lfs↵  
  
git init↵  
  
git lfs install↵
```

图 4- 13 初始化代码

```
终端 1
Get:33 https://repo.huaweicloud.com/ubuntu jammy-security/universe amd64 Packages [1241 kB]
Get:34 https://repo.huaweicloud.com/ubuntu jammy-updates/multiverse Sources [30.6 kB]
Get:35 https://repo.huaweicloud.com/ubuntu jammy-updates/universe Sources [563 kB]
Get:36 https://repo.huaweicloud.com/ubuntu jammy-updates/restricted Sources [96.2 kB]
Get:37 https://repo.huaweicloud.com/ubuntu jammy-updates/main Sources [679 kB]
Get:38 https://repo.huaweicloud.com/ubuntu jammy-updates/multiverse amd64 Packages [55.7 kB]
Get:39 https://repo.huaweicloud.com/ubuntu jammy-updates/restricted amd64 Packages [4148 kB]
Get:40 https://repo.huaweicloud.com/ubuntu jammy-updates/main amd64 Packages [3092 kB]
Get:41 https://repo.huaweicloud.com/ubuntu jammy-updates/universe amd64 Packages [1540 kB]
Fetched 65.7 MB in 3s (19.3 MB/s)
Reading package lists... Done
root@autodl-container-b3ec4da47b-18422fed:~/autodl-tmp# apt-get install git-lfs
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
The following NEW packages will be installed:
  git-lfs
0 upgraded, 1 newly installed, 0 to remove and 148 not upgraded.
Need to get 3544 kB of archives.
After this operation, 10.5 MB of additional disk space will be used.
Get:1 https://repo.huaweicloud.com/ubuntu jammy-security/universe amd64 git-lfs amd64 3.0.2-1ubuntu0.3 [3544 kB]
Fetched 3544 kB in 0s (7173 kB/s)
debconf: delaying package configuration, since apt-utils is not installed
Selecting previously unselected package git-lfs.
(Reading database ... 47631 files and directories currently installed.)
Preparing to unpack .../git-lfs_3.0.2-1ubuntu0.3_amd64.deb ...
Unpacking git-lfs (3.0.2-1ubuntu0.3) ...
Setting up git-lfs (3.0.2-1ubuntu0.3) ...
root@autodl-container-b3ec4da47b-18422fed:~/autodl-tmp# git init
hint: Using 'master' as the name for the initial branch. This default branch name
hint: is subject to change. To configure the initial branch name to use in all
hint: of your new repositories, which will suppress this warning, call:
hint:
hint:   git config --global init.defaultBranch <name>
hint:
hint: Names commonly chosen instead of 'master' are 'main', 'trunk' and
hint: 'development'. The just-created branch can be renamed via this command:
hint:
hint:   git branch -m <name>
Initialized empty Git repository in /root/autodl-tmp/.git/
root@autodl-container-b3ec4da47b-18422fed:~/autodl-tmp# git lfs install
```

图 4-14 初始化后终端页面

4.6.2 部署 LLaMA-Factory

`git clone --depth 1 https://github.com/hiyouga/LLaMA-Factory.git`

```
root@autodl-container-05cf41b0f8-b95d1785: /autodl-tmp# git clone --depth 1 https://github.com/hiyouga/LLaMA-Factory.git
Cloning into 'LLaMA-Factory'...
remote: Enumerating objects: 350, done.
remote: Counting objects: 100% (350/350), done.
remote: Compressing objects: 100% (270/270), done.
remote: Total 350 (delta 93), reused 210 (delta 65), pack-reused 0 (from 0)
Receiving objects: 100% (350/350), 9.59 MiB | 455.00 KiB/s, done.
Resolving deltas: 100% (93/93), done.
root@autodl-container-05cf41b0f8-b95d1785:~/autodl-tmp#
```

图 4-15 部署llama-factory

4.6.3 下载环境依赖

```
conda create -n sft python=3.10<

source activate sft <

pip install -i https://pypi.tuna.tsinghua.edu.cn/simple -e

".[torch,metrics]"<
```

图 4- 16 下载环境依赖代码

```
(sft) root@autodl-container-b3ec4da7b-18422fed:~/autodl-tmp/LLaMA-Factory# pip install -i https://pypi.tuna.tsinghua.edu.cn/simple -e ".[torch,metrics]"
Looking in indexes: https://pypi.tuna.tsinghua.edu.cn/simple
Obtaining file:///root/autodl-tmp/LLaMA-Factory
Installing build dependencies ... done
Checking if build backend supports build_editable ... done
Getting requirements to build editable ... done
Preparing editable metadata (pyproject.toml) ... done
Collecting transformers!=4.46.*,!=4.47.*,!=4.48.0,<=4.51.0,>=4.41.2 (from llamafactory==0.9.3.dev0)
Downloading https://pypi.tuna.tsinghua.edu.cn/packages/6f/db/7ee15028d5130929aa0b1b85bab6d8baf806254d3b5c56c42a0066cceb8/transformers-4.51.0-py3-none-any.whl (10.4 MB)
10.4/10.4 MB 30.3 MB/s eta 0:00:00
Collecting datasets<=3.4.1,>=2.16.0 (from llamafactory==0.9.3.dev0)
Downloading https://pypi.tuna.tsinghua.edu.cn/packages/16/44/5de560a2625d31801895fb2663693df210c6465960d61a99192caa9afd63/datasets-3.4.1-py3-none-any.whl (487 kB)
Collecting accelerate<=1.5.2,>=0.34.0 (from llamafactory==0.9.3.dev0)
Downloading https://pypi.tuna.tsinghua.edu.cn/packages/70/83/167d4b638bb758a966828eb8d23c5e7047825eddf768ff5f4fb01440063/accelerate-1.5.2-py3-none-any.whl (345 kB)
```

图 4- 17 下载环境依赖

4.6.4 下载 vllm 加速推理

```
pip install -i https://pypi.tuna.tsinghua.edu.cn/simple vllm
pip install accelerate
pip install bitsandbytes
```

```
WARNING: Running pip as the 'root' user can result in broken permissions and conflicting behaviour with the system package manager, possibly rendering your system unusable. It is recommended to use a virtual environment instead: https://pip.pypa.io/warnings/venv. Use the --root-user-action option if you know what you are doing and want to suppress this warning.
(sft) root@autodl-container-b3ec4da7b-18422fed:~/autodl-tmp/LLaMA-Factory# pip install -i https://pypi.tuna.tsinghua.edu.cn/simple vllm
Looking in indexes: https://pypi.tuna.tsinghua.edu.cn/simple
Collecting vllm
  Downloading https://pypi.tuna.tsinghua.edu.cn/packages/2a/99/58ba40e42ec6358ff4da5b6b6ce2ac9f8b10329fcfd65c9ee12c124f37f9/vllm-0.8.3-cp38-abi3-manylinux2014_x86_64.whl (294.0 MB)
```

图 4- 18 下载vllm

4.6.5 启动 web 界面

```
root@autodl-container-6f0845bdc9-14e4800c:~# source activate sft
(sft) root@autodl-container-6f0845bdc9-14e4800c:~# cd LLaMA-Factory
bash: cd: LLaMA-Factory: No such file or directory
(sft) root@autodl-container-6f0845bdc9-14e4800c:~# cd autodl-tmp
(sft) root@autodl-container-6f0845bdc9-14e4800c:~/autodl-tmp# cd LLaMA-Factory
(sft) root@autodl-container-6f0845bdc9-14e4800c:~/autodl-tmp/LLaMA-Factory# llamafactory-cli webui
INFO 04-08 19:16:06 [_init_.py:239] Automatically detected platform cuda.
Visit http://ip:port for Web UI, e.g., http://127.0.0.1:7860
* Running on local URL: http://0.0.0.0:7860

To create a public link, set `share=True` in `launch()`.
```


图 4- 19 LLaMA-Factory

第 5 章 测试分析

5.1 智诊 AI 医疗大模型的回答




图 5- 1 智诊科技开放平台

5.2 单个大语言模型的回答



图 5- 2 deepseek

5.3 Team 实现多 Agent 的回答




图 5- 3 多agent

第 6 章 作品总结

6.1 作品特色与创新点

本系统首次将 LoRA 轻量化指令监督微调与动态 RAG 检索深度融合，构建了从数据预处理、模型微调、知识抓取与向量检索到多智能体协同决策的全流程框架。在 Autogen Studio 的 Team 架构下，检索 (bge-m3)、初步生成 (gpt4o-mini)、专业增强 (deepseek-r1) 和汇总四大 Agent 各司其职、并行弹性扩容，真正实现了“动态同步知识→结构化生成→领域深度校正→统一输出”闭环。该方案不仅显著提高了医疗文本决策的实时性和专业性，也凭借模块化设计与工具链可插拔能力，为金融风控、法律咨询等高风险场景下的可审计自动化决策提供了可复制、可扩展的新范式。

6.2 应用推广

基于系统化推广战略，本方案确立两大实施目标：一是提升智能辅助诊疗系统在医患群体中的认知度与应用渗透率，二是构建人机协同的新型医疗服务范式。通过构建“线上-线下”复合型推广体系，整合数字传播、机构合作与场景化实践三大路径。

6.2.1 数字传播矩阵建设

（1）依托主流媒体构建技术传播矩阵，通过可视化案例解析与场景模拟演示增强用户感知。

（2）搭建在线学术交流平台，组织系列技术研讨会与案例工作坊，形成跨机构知识共享网络。

6.2.2 多维度场景渗透

（1）构建三级临床验证网络：在试点医院开展深度技术集成，设计渐进式应用场景（从辅助读片到治疗方案优化），同步建立动态反馈机制。

（2）打造学术推广双通道：通过国际医学会议展示技术突破，依托区域性医疗联盟开展技术路演，形成“前沿研究-临床应用”转化闭环。

（3）实施公益赋能计划：在医联体框架内开展智能诊疗基层行活动，结合远程会诊场景验证技术普适性，累积社会效益数据。

6.2.3 行业生态构建

建立包含技术供应商、医疗机构、监管部门的协同创新联盟，制定技术采纳成熟度评估模型，重点突破院内 workflow 整合瓶颈。通过成本效益分析工具量化 ROI 指标，形成可复制的商业推广模式。

6.3 作品展望

6.3.1 功能体系纵向延伸

在现有患者全生命周期管理、智能分诊咨询等基础功能模块基础上，着力构建第二增长曲线：（1）个性化诊疗决策支持引擎，实现治疗方案动态优化与疗效预测的闭环管理（2）智能随访干预系统，构建患者依从性评估模型与自适应健康干预策略。

重点突破三大新兴领域：（1）群体健康画像系统：开发区域性疾病热力图谱与流行病学预测模型（2）医疗资源动态配置平台：构建基于强化学习的床位调度与手术室优化算法（3）医患认知对齐系统：创新医疗知识可视化解释与风险沟通机制。

6.3.2 技术架构迭代升级

核心算法突破：（1）影像诊断增强：采用三维卷积注意力网络（3D-CA-Net）提升 DICOM 图像解析精度。（2）自然语言理解：部署医疗专用语义理解引擎（Med-BERT）。

6.3.3 安全防护体系强化

构建医疗数据安全立方体：（1）传输层：采用动态同态加密机制保障数据流转安全。（2）存储层：实施基于区块链的分布式碎片化存储方案。（3）应用层：部署差分隐私保护框架，确保模型推理过程满足 GDPR 合规要求。

6.3.4 行业影响与价值展望

1. 轻量化微调技术的普及与优化

未来，大模型轻量化微调技术，如 LoRA（Low-Rank Adaptation）等，将在更多应用场景中得到广泛普及。针对不同任务特点，将进一步探索更高效的微调方法，包括稀疏适配（Sparse Adaptation）、参数高效微调（PEFT）等，以降低存储与算力开销，同时提升模型个性化能力与迁移效率。此外，针对轻量化微调的自动化参数优化（Auto-LoRA）和自适应调控策略也将成为重要研究方向，进一步提升微调精度与稳定性。

2. 动态 RAG 与多模态知识图谱的深度融合

基于检索增强生成（RAG, Retrieval-Augmented Generation）的动态集成框架，未来将更加注重与多模态知识图谱（涵盖文本、图像、音频等多源异构数据）的紧密结合。动态 RAG 系统将不仅实现基于实时环境变化的检索内容更新，还能够推理过程中灵活调用不同模态信息，增强模型的推理能力与知识完整性。同时，将推动知识组织、推理路径优化及跨模态知识对齐等方面的创新，提升系统在复杂开放环境下的适应性和智能决策水平。

3. team 实现多个 agent 协同处理

借助 Autogen Studio 中的 Team 架构，多智能体协同处理文本决策流程将为各行各业带来显著创新价值：首先，通过检索、初步生成、专业增强和汇总四大 Agent 的分工协作，不仅可大幅缩短从信息获取到决策输出的响应时延，而且各环节可并行扩容，满足大规模场景下的实时决策需求；其次，开放式的 Team 配置与工具链（如 Fetch Webpage、向量库、LoRA 微调等）可无缝对接行业专属数据源与知识图谱，降低落地门槛，并促进跨领域智能体复用与快速迭代；最后，动态更新的 RAG 检索与 Domain-tuned 生成相结合，为金融风控、法律咨询、智能客服、精准营销等场景提供更可靠、更可审计的自动化决策方案，助推企业实现 AI 驱动的业务革新与成本优化。

4. 医疗领域的可信性与伦理体系建设

随着大模型在医疗诊断、辅助决策和科研辅助等领域的逐步应用，确保系统可信性与建立完善的伦理体系将成为未来发展的核心议题。未来的研究将重点围绕模型输出的可解释性、数据隐私保护、偏差控制与公平性验证等方面展开，推动制定符合国际标准的医疗 AI 监管框架。同时，将鼓励引入“人机协同审查机

制”，确保模型建议由专业人员最终验证，从而在提升医疗服务效率的同时，保障患者安全与社会信任。

参考文献

- [1]Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1135-1144.
- [2]Topol, E. J. (2019). High-performance medicine: The convergence of human and artificial intelligence. *Nature Medicine*, 25(1), 44-56.7
- [3]颜见智,何雨鑫,骆子烨,胡晗,范士喜,汤步洲.生成式大语言模型在医疗领域的潜在典型应用与面临的挑战[J].医学信息学杂志,2023,44(09):23-31.
- [4]Xu, J., et al. (2021). Federated learning for healthcare informatics. *Journal of Healthcare Informatics Research*, 5(1), 1-19.[citation:9]
- [5] Li, M., et al. (2024). From challenges and pitfalls to recommendations and opportunities: Implementing federated learning in healthcare. *Medical Image Analysis*, 102(3), 103-120.
- [6] Zhou, X., et al. (2023). Overview of large-scale language models in healthcare: Transformative roles and clinical applications. *Journal of Medical Artificial Intelligence*, 6(4), 45-59.
- [7] Upreti, D., Yang, E., Kim, H., & Seo, C. (2024). A comprehensive survey on federated learning in the healthcare area: Concept and applications. *Computer Modeling in Engineering & Sciences*, 140(3), 2239-2274.